

Warszawa, 16.06.2021

Politechnika Warszawska
Wydział Elektroniki i Technik Informacyjnych

Sieci neuronowe w zastosowaniach biomedycznych (SNB)

Projekt: (35) Diagnostyka raka piersi w badaniach
mammograficznych za pomocą sieci MLP

ETAP III

Prowadzący: dr inż. Paweł Mazurek

Wykonawca:

Zespół 4

Jagoda Adamczyk, Aleksandra Krakowiak

Spis treści

1	Wstęp	3
2	Model sieci	3
2.1	Struktura sieci.....	3
2.2	Algorytm uczenia	3
3	Optymalizacja.....	4
3.1	Parametry wykorzystywane do oceny skuteczności optymalizacji.....	4
3.1.1	Czułość.....	4
3.1.2	Specyficzność	4
3.1.3	Błąd średniokwadratowy	4
3.2	Zmiana zakresu uwzględnianych danych.....	5
3.2.1	Wyniki.....	5
3.2.2	Porównanie uzyskanych wyników.....	7
3.2.3	Wnioski	9
3.3	Zmiana współczynnika szybkości uczenia sieci	9
3.3.1	Wyniki.....	9
3.3.2	Porównanie uzyskanych wyników.....	15
3.3.3	Wnioski	16
3.4	Zmiana liczby neuronów w warstwie ukrytej	17
3.4.1	Wyniki.....	17
3.4.2	Porównanie uzyskanych wyników.....	19
3.4.3	Wnioski	21
3.5	Zmiana liczby neuronów w warstwie ukrytej	21
3.5.1	Wyniki.....	22
3.5.2	Porównanie uzyskanych wyników i wnioski.....	29
4	Końcowy model sieci	30
4.1	Struktura sieci.....	30
4.2	Algorytm uczenia	30
4.3	Porównanie wyników przed optymalizacją z wynikami po optymalizacji	30
5	Bibliografia.....	33
6	Oświadczenie.....	33

1 Wstęp

Celem wykonywanego projektu jest stworzenie sieci MLP. Zadaniem stworzonej sieci, będzie zakwalifikowanie kobiet do jednej z dwóch grup – łagodnej zmiany mammograficznej lub złośliwej. Klasyfikacja ta umożliwiłaby zmniejszenie liczby wykonywanych niepotrzebnych biopsji. Powyższa klasyfikacja opiera się na zebranych wcześniej informacjach mammograficznych. W projekcie wykorzystywana będzie baza – *Mammographic Mass Data Set*¹, która zawiera dane od 516 kobiet o łagodnej zmianie mammograficznej oraz 445 – złośliwej zmianie. Zestaw danych wejściowych ma charakter wielowymiarowy.

Celem trzeciego etapu projektu jest optymalizacja struktury sieci oraz algorytmu uczenia sieci. Wykorzystywany algorytm został zaimplementowany w środowisku MATLAB na podstawie modelu z II etapu tego projektu. Do określenia użyteczności zoptymalizowanej sieci oraz algorytmu posłużono się wartościami wskaźników czułości i specyficzności.

Projekt będzie wykonywany przy wykorzystaniu oprogramowania MATLAB R2021a przy wykorzystaniu Matlab Driver. Matlab Driver umożliwia współdzielenie pliku, dzięki czemu możliwa jest praca na jednym pliku.

2 Model sieci

We wcześniejszym etapie projektu model sieci został opisany szczegółowo. W tym rozdziale przypomnimy założenia stworzonej przez nas sieci.

2.1 Struktura sieci

Zaprojektowana przez nas sieć to sieć dwuwarstwowa perceptronowa jednokierunkowa. Sieć składa się z pięciu neuronów wejściowych (odpowiedniki – atrybuty w bazie) oraz trzech neuronów w warstwie ukrytej. Wynik działania sieci przyjmuje charakter binarny (0 lub 1) oznacza to, że na wyjściu zastosowano jeden neuron wyjściowy. Wszystkie neurony z warstwy wejściowej są połączone bezpośrednio ze wszystkimi neuronami warstwy ukrytej. Neurony warstwy ukrytej są połączone z neuronem wyjściowym.

2.2 Algorytm uczenia

Odwołując się do realizacji etapu drugiego projektu dane wejściowe zostały poddane standaryzacji, aby w równym stopniu włączyły się do wyznaczania wartości wyjściowej. Następnie wszystkie dostępne dane zostały podzielone na zbiory treningowe i testowe (15% całego zbioru). Podczas realizacji wcześniejszego etapu założyliśmy, że funkcją aktywacji warstwy ukrytej i warstwy wyjściowej będzie funkcja tangensa hiperbolicznego. Uczenie sieci polegało na użyciu algorytmu propagacji wstecznej. Próg decyzyjności to 0.5. Wartości mniejsze niż 0.5 przyjmowały wartość wyjściową $y = 0$ (łagodna zmiana), a wartości większe lub równe 0.5 – złośliwa zmiana ($y = 1$)

3 Optymalizacja

3.1 Parametry wykorzystywane do oceny skuteczności optymalizacji

Do oceny skuteczności optymalizacji wykorzystano wskaźniki czułości i specyficzności. Wyliczono również błędy średniokwadratowe dla danych treningowych i testowych. Wszystkie wyżej wymienione wskaźniki podlegały porównaniom.

3.1.1 Czułość

Czułość (ang. *sensitivity – true positive rate* TPR) to wskaźnik opisujący stosunek wyników prawdziwie pozytywnych (TP – *true positive*) do sumy wyników prawdziwych pozytywnych (TP) i fałszywych negatywnych (FN – *false negative*).

$$TPR = \frac{TP}{TP+FN} \quad (3.1)$$

Inaczej jest to prawdopodobieństwo uzyskania wyniku pozytywnego w teście rozpoznającym chorobę u prawdziwie chorej osoby.

3.1.2 Specyficzność

Specyficzność (ang. *specificity – true negative rate* TNR) opisuje stosunek wyników prawdziwie negatywnych (TN – *true negative*) do sumy wyników prawdziwie negatywnych (TN) i fałszywie pozytywnych (FP – *false positive*).

$$TNR = \frac{TN}{TN+FP} \quad (3.2)$$

Inaczej jest prawdopodobieństwo otrzymania negatywnego wyniku w teście rozpoznającym chorobę przez osobę prawdziwie zdrową.

3.1.3 Błąd średniokwadratowy

Błąd średniokwadratowy był obliczany dla danych testowych oraz treningowych wg wzoru (3.3)

$$\frac{1}{N} \sum_{i=1}^N (d_i - y_i)^2 \quad (3.3)$$

gdzie:

d_i – wartość oczekiwana elementu i

y_i – wartość uzyskana elementu i

N – liczebność zbioru danych

3.2 Zmiana zakresu uwzględnianych danych

Pierwszym krokiem w etapie optymalizacji to sprawdzenie, czy zmiana zakresu uwzględnianych danych ma wpływ na uzyskiwane wyniki i jakość działania sieci. Wykonanie tego sprawdzenia polegało na wyliczeniu wartości czułości, specyficzności oraz błędu średniokwadratowego dla danych testowych i treningowych przy eliminacji kolejnych cech. Przeprowadzono próby: dla wszystkich danych (próba kontrolna), bez *BI-RADS*, bez *Age*, bez *Shape*, bez *Margin*, bez *Density*. Wszystkie inne parametry pozostały bez zmian (współczynnik szybkości uczenia sieci $\alpha = 0.001$, liczba cykli – 100 000 oraz ilość neuronów w warstwie ukrytej $n = 3$)

3.2.1 Wyniki

W poniższych tabelach (Tabela 1 – 6) przedstawiono wyniki z 6 prób wartości czułości, specyficzności i błędów średniokwadratowych dla każdego przypadku i próby kontrolnej.

Próba ze wszystkimi danymi

Tabela 1. Próba kontrolna - wszystkie dane

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,6923	0,7419	0,8356	0,6129	0,8382	0,7746	0,74925
Specyficzność	0,8987	0,8537	0,8732	0,9756	0,8816	0,9315	0,90238
Błąd MSE treningowe	0,00022	0,00014	0,00014	0,00014	0,00015	0,00017	0,00016
Błąd MSE testowe	0,19440	0,19440	0,14580	0,18060	0,13890	0,14580	0,16665

Próba bez *BI-RADS*

Tabela 2. Wyniki uzyskane przy wyeliminowaniu cechy *BI-RADS*

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7671	0,8824	0,8551	0,9194	0,8382	0,8125	0,84578
Specyficzność	0,7606	0,8289	0,8000	0,8293	0,8158	0,8875	0,82035
Błąd MSE treningowe	0,00016	0,00018	0,00017	0,00018	0,00017	0,00018	0,00017
Błąd MSE testowe	0,23610	0,14580	0,17360	0,13190	0,17360	0,14580	0,16780

Próba bez Age

Tabela 3. Wyniki uzyskane przy wyeliminowaniu cechy Age

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,8000	0,8491	0,7941	0,8667	0,8082	0,7778	0,81598
Specyficzność	0,8108	0,8022	0,8684	0,7857	0,8451	0,8642	0,82940
Błąd MSE treningowe	0,00015	0,00015	0,00014	0,00015	0,00015	0,00015	0,00015
Błąd MSE testowe	0,19440	0,18060	0,1667	0,1806	0,1736	0,1736	0,17825

Próba bez Shape

Tabela 4. Wyniki uzyskane przy wyeliminowaniu cechy Shape

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7971	0,7455	0,8000	0,8158	0,7647	0,8030	0,78768
Specyficzność	0,9600	0,8652	0,8784	0,8235	0,9079	0,8974	0,88873
Błąd MSE treningowe	0,00015	0,00015	0,00014	0,00015	0,00016	0,00016	0,00015
Błąd MSE testowe	0,1181	0,1806	0,1597	0,1806	0,1597	0,1458	0,15742

Próba bez Margin

Tabela 5. Wyniki uzyskane przy wyeliminowaniu cechy Margin

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,8077	0,8657	0,8000	0,6875	0,6719	0,6774	0,74170
Specyficzność	0,8261	0,8571	0,8987	0,9688	0,8875	0,8537	0,88198
Błąd MSE treningowe	0,00014	0,00015	0,00015	0,00014	0,00015	0,00016	0,00015
Błąd MSE testowe	0,1806	0,1389	0,1458	0,1875	0,2083	0,2222	0,18055

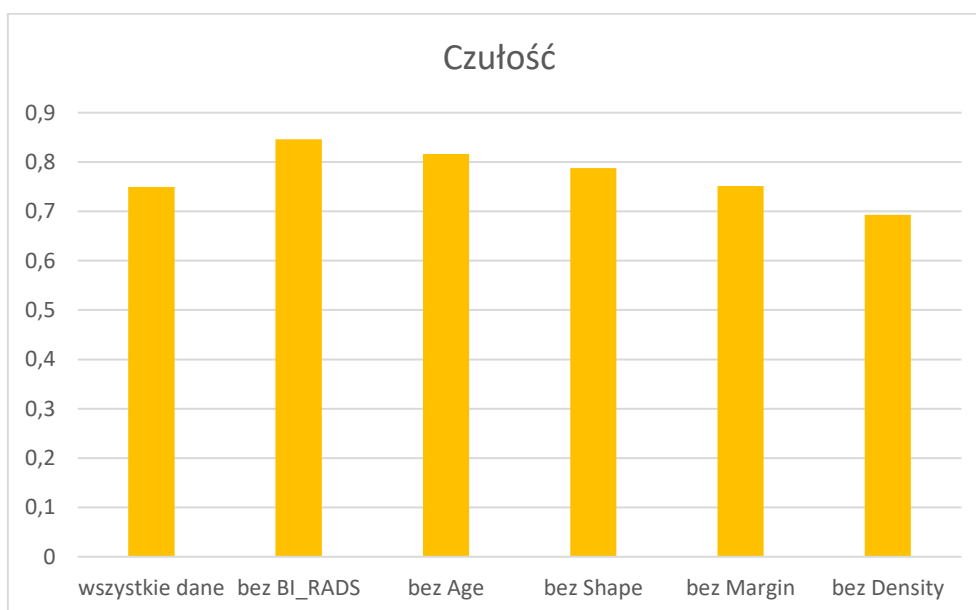
Próba bez *Density*

Tabela 6. Wyniki uzyskane przy wyeliminowaniu cechy *Density*


Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7222	0,6711	0,7538	0,6984	0,6761	0,6349	0,69275
Specyficzność	0,9444	0,9559	0,7975	0,9012	0,8493	0,9136	0,89365
Błąd MSE treningowe	0,00013	0,00014	0,00018	0,00013	0,00022	0,00013	0,00016
Błąd MSE testowe	0,1667	0,1944	0,2222	0,1875	0,2361	0,2083	0,20253

3.2.2 Porównanie uzyskanych wyników


W celu poprawnej analizy uzyskanych wyników wykreślono wykresy, które umożliwią porównanie uzyskanych wyników. Wykresy przedstawiają wartości sprawdzanych parametrów w zależności od zakresu danych wejściowych (Wykres 1-4).




Wykres 1. Wykres wartości czułości w różnych zakresach danych wejściowych



Wykres 2. Wykres wartości specyficzności w różnych zakresach danych wejściowych



Wykres 3. Wykres wartości błędu średniokwadratowego dla danych treningowych w różnych zakresach danych wejściowych



Wykres 4. Wykres wartości błędu średniokwadratowego dla danych testowych w różnych zakresach danych wejściowych

3.2.3 Wnioski

Wykresy z poprzedniego podrozdziału umożliwiły analizę uzyskanych wyników. Analiza nie pozwala na wyeliminowanie konkretnego atrybutu wejściowego. Należy jednak zwrócić uwagę, że podczas wyeliminowania atrybutu *BI-RADS* błąd średniokwadratowy zwiększył się (widoczna zmiana). Możemy wnioskować, że szczególne znaczenie ma skala opisująca wynik badania mammograficznego. Należy również zwrócić uwagę na obniżenie wartości specyficzności przy wyeliminowaniu *BI-RADS* i *Age*. Po analizie otrzymanych wyników postanowiono o pozostawieniu wszystkich atrybutów wejściowych do kolejnych analiz i do ostatecznego rozwiązania.

3.3 Zmiana współczynnika szybkości uczenia sieci

W kolejnym etapie optymalizacji sprawdzono jaki wpływ na uzyskane wartości parametrów czułości, specyficzności i błędów średniokwadratowych ma zmiana współczynnika szybkości uczenia sieci. Analizie poddano siedem różnych wartości współczynnika szybkości uczenia sieci: 0,001; 0,01; 0,1; 0,25; 0,5; 0,85; 0,99. Próby wykonano przy założeniu 100 000 cykli oraz 3 neuronach warstwy ukrytej.


3.3.1 Wyniki

W poniższych tabelach (Tabela 7 – 13) przedstawiono wartości parametrów omówionych w rozdziale 3.1. Dla każdego współczynnika szybkości uczenia wykreślono wykresy (Wykres 5 – 11) zależności wartości błędów średniokwadratowych od iteracji dla danych treningowych.

$\alpha = 0,001$

Tabela 7. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,001$

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,6716	0,8182	0,7838	0,8667	0,8000	0,6970	0,77288
Specyficzność	0,8961	0,8060	0,9143	0,8571	0,8649	0,9487	0,88118
Błąd MSE treningowe	0,00014	0,00014	0,00014	0,00015	0,00015	0,00014	0,00014
Błąd MSE testowe	0,2083	0,1875	0,1528	0,1389	0,1667	0,1667	0,17015




Wykres 5. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,001$

$\alpha = 0,01$

Tabela 8. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,01$

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,6912	0,6761	0,6970	0,6324	0,6774	0,6757	0,67497
Specyficzność	0,9342	0,9589	0,9359	0,8816	0,9146	0,8857	0,91848
Błąd MSE treningowe	0,00015	0,00015	0,00014	0,00013	0,00015	0,00014	0,00014
Błąd MSE testowe	0,1806	0,1806	0,1736	0,2361	0,1875	0,2222	0,19677




Wykres 6. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,01$

$\alpha = 0,1$

Tabela 9. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,1$

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,2535	0,1791	0	0,0758	0,0606	0,0145	0,09725
Specyficzność	1	0,9870	0,9880	1	1	1	0,99583
Błąd MSE treningowe	0,0001	0,0001	0,00018	0,00018	0,00019	0,0001	0,00014
Błąd MSE testowe	0,3681	0,3889	0,4306	0,4236	0,4306	0,4722	0,41900




Wykres 7. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,1$

$\alpha = 0,25$

Tabela 10. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,25$

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0	0,0143	0,6230	0	0,6563	0	0,21560
Specyficzność	1	0,9865	0,9398	1	0,9250	1	0,97522
Błąd MSE treningowe	0,0002	0,00022	0,00012	0,00012	0,0001	0,0001	0,00014
Błąd MSE testowe	0,3958	0,4861	0,1944	0,5139	0,1944	0,5139	0,38308




Wykres 8. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,25$

$\alpha = 0,5$

Tabela 11. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,5$

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,0175	0	0,0429	0,0137	0	0,8276	0,15028
Specyficzność	0,9770	1	1	1	1	0,7558	0,95547
Błąd MSE treningowe	0,00022	0,0001	0,00011	0,0002	0,00013	0,00018	0,00016
Błąd MSE testowe	0,4028	0,4444	0,4653	0,5000	0,4306	0,2153	0,40973




Wykres 9. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,5$

$\alpha = 0,85$

Tabela 12. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,85$

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0	0	0	0,7361	0,0147	0,0333	0,13068
Specyficzność	1	1	0,9982	0,0972	0,9737	0,9286	0,83295
Błąd MSE treningowe	0,00036	0,00023	0,00036	0,00027	0,00015	0,00034	0,00029
Błąd MSE testowe	0,5417	0,4583	0,4167	0,5833	0,4792	0,4444	0,48727




Wykres 10. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,85$

$\alpha = 0,99$

Tabela 13. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,99$


Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,0417	0,9531	0,9589	0,0588	0,8714	0,1029	0,4978
Specyficzność	0,9861	0,1500	0,2254	0,3158	0,7027	0,8816	0,5436
Błąd MSE treningowe	0,00023	0,00031	0,00034	0,00021	0,00021	0,00029	0,00027
Błąd MSE testowe	0,4861	0,4931	0,4028	0,8056	0,2153	0,4861	0,4815




Wykres 11. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0,99$

3.3.2 Porównanie uzyskanych wyników


W celu poprawnej analizy poszczególnych wartości parametrów dla kolejnych wartości współczynnika szybkości uczenia wykreślono poniższe wykresy (Wykres 12 – 15).



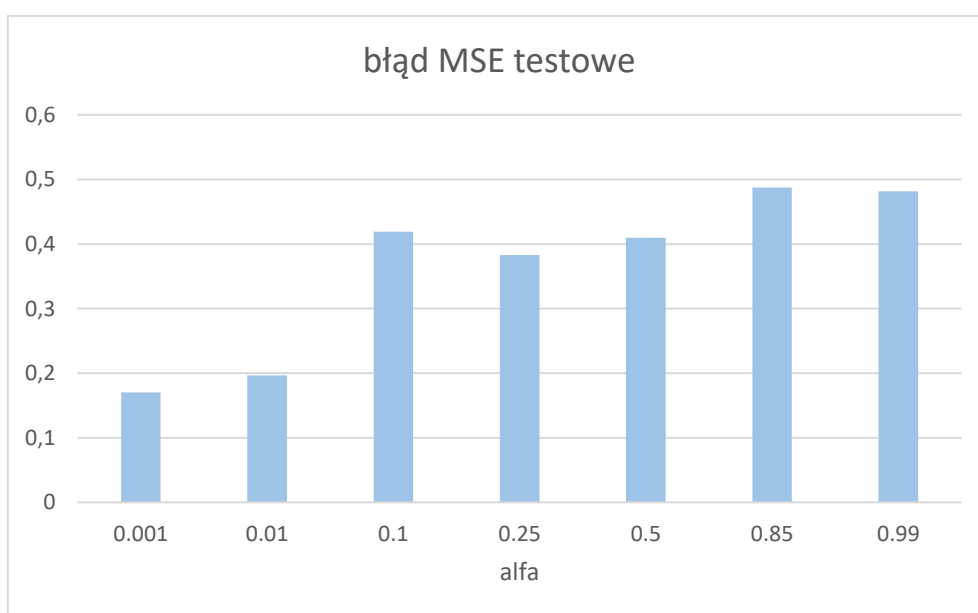
Wykres 12. Wykres wartości czułości przy różnych wartościach współczynnika szybkości uczenia



Wykres 13. Wykres wartości specyficzności przy różnych wartościach współczynnika szybkości uczenia



Wykres 14. Wykres wartości błędu średniokwadratowego dla danych treningowych przy różnych wartościach współczynnika szybkości uczenia



Wykres 15. Wykres wartości błędu średniokwadratowego dla danych testowych przy różnych wartościach współczynnika szybkości uczenia

3.3.3 Wnioski

Na podstawie wszystkich dostępnych informacji przedstawionych we wcześniejszych podrozdziałach można zauważyć, że im większy współczynnik szybkości uczenia sieci tym wartości błędu średniokwadratowego przyjmują większe wartości oraz ich poziom stabilizacji zostaje naruszony. Przy $\alpha = 0,001$ zauważamy, że błąd stabilizuje się przy ok 10^2 iteracji, a przy $\alpha = 0,25$ już ta stabilizacja zostaje naruszona oraz nie jest tak łagodna zmiana jak we wcześniejszym przypadku. W analizie najlepiej na tle innych wartości współczynnika szybkości uczenia wypadły $\alpha = 0,001$ oraz $\alpha = 0,01$ (przy założeniu 100 000

cykli). Przy tych wartościach współczynnika 3 z 4 badanych paramentów są na podobnym poziomie. Natomiast przy mniejszej wartości α wartość błędu średniokwadratowego dla danych testowych jest mniejsza niż dla $\alpha = 0,01$. Co przemawia za wyborem $\alpha = 0,001$. Podczas realizacji II etapu projektu od samego początku zakładaliśmy $\alpha = 0,001$.

3.4 Zmiana liczby neuronów w warstwie ukrytej

W trzecim etapie optymalizacji przeprowadzono analizę jaki wpływ ma zmiana ilość neuronów w warstwie ukrytej na wartości parametrów: czułość, specyficzność, błąd średniokwadratowy (dla danych testowych i treningowych). Próby wykonano dla 2, 3, 5, 6, 8, 10 neuronów w warstwie ukrytej. Zakładamy, że ilość cykli to 100 000 oraz współczynnik szybkości uczenia sieci wynosi 0,001.

3.4.1 Wyniki

Poniżej przedstawiono tabele (Tabela 14 – 19), które zawierają w sobie otrzymane wartości badanych parametrów dla kolejnych przyjmowanych ilości neuronów w warstwie ukrytej.

n = 2

Tabela 14. Wartości uzyskane dla sieci o 2 neuronach w warstwie ukrytej

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7532	0,6986	0,7031	0,7206	0,6000	0,7761	0,70860
Specyficzność	0,8358	0,8873	0,9750	0,8947	0,9494	0,8571	0,89988
Błąd MSE treningowe	0,00015	0,00016	0,00028	0,00016	0,00027	0,00016	0,00020
Błąd MSE testowe	0,2083	0,2083	0,1485	0,1875	0,2083	0,1806	0,19025

n = 3

Tabela 15. Wartości uzyskane dla sieci o 3 neuronach w warstwie ukrytej

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7206	0,6923	0,7419	0,8356	0,5741	0,6129	0,69623
Specyficzność	0,8421	0,8987	0,8537	0,8732	0,9556	0,9756	0,89982
Błąd MSE treningowe	0,00014	0,00022	0,00014	0,00014	0,00014	0,00014	0,00015
Błąd MSE testowe	0,2153	0,1944	0,1944	0,1458	0,1875	0,1806	0,18633

n = 5

Tabela 16. Wartości uzyskane dla sieci o 5 neuronach w warstwie ukrytej

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7903	0,7903	0,9054	0,8148	0,7119	0,8056	0,80305
Specyficzność	0,8780	0,8293	0,7429	0,8889	0,8471	0,9722	0,85973
Błąd MSE treningowe	0,00014	0,00013	0,00013	0,00014	0,00013	0,00013	0,00013
Błąd MSE testowe	0,1597	0,1875	0,1736	0,1389	0,2083	0,1111	0,16318

n = 6

Tabela 17. Wartości uzyskane dla sieci o 6 neuronach w warstwie ukrytej

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7606	0,7500	0,8514	0,8312	0,7324	0,8197	0,79088
Specyficzność	0,9315	0,8929	0,8571	0,7910	0,8219	0,8795	0,86232
Błąd MSE treningowe	0,00012	0,00013	0,00013	0,00012	0,00014	0,00013	0,00013
Błąd MSE testowe	0,1528	0,1667	0,1458	0,1875	0,2222	0,1458	0,17013

n = 8

Tabela 18. Wartości uzyskane dla sieci o 8 neuronach w warstwie ukrytej

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,7273	0,8028	0,7826	0,7983	0,7188	0,7619	0,76528
Specyficzność	0,8333	0,8630	0,9200	0,8892	0,8125	0,8889	0,86782
Błąd MSE treningowe	0,00013	0,00012	0,00012	0,00012	0,00011	0,00013	0,00012
Błąd MSE testowe	0,2153	0,1667	0,1458	0,1944	0,2292	0,1667	0,18635


n = 10

Tabela 19. Wartości uzyskane dla sieci o 10 neuronach w warstwie ukrytej


Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,9000	0,7571	0,7639	0,8615	0,9000	0,7910	0,82892
Specyficzność	0,7969	0,8649	0,9306	0,8861	0,7703	0,8961	0,85748
Błąd MSE treningowe	0,00012	0,00012	0,00012	0,00012	0,00012	0,00012	0,00012
Błąd MSE testowe	0,1458	0,1875	0,1528	0,1596	0,1667	0,1528	0,16087

3.4.2 Porównanie uzyskanych wyników


W celu łatwiejszego porównania i analizy wykreślono wykresy (Wykres 16 -19), które umożliwiają porównanie poszczególnych parametrów dla kolejnych przyjętych ilości neuronów w warstwie ukrytej.




Wykres 16. Wykres wartości czułości od ilości neuronów w warstwie ukrytej



Wykres 17. Wykres wartości specyficzności od ilości neuronów w warstwie ukrytej



Wykres 18. Wykres wartości błędu średniokwadratowego dla danych treningowych od ilości neuronów w warstwie ukrytej



Wykres 19. Wykres wartości błędu średniokwadratowego dla danych testowych od ilości neuronów w warstwie ukrytej

3.4.3 Wnioski

Nasz wektor wejściowych posiada 5 atrybutów. Oznacza to, że ilość neuronów w warstwie ukrytej powinna być mniejsza niż ilość neuronów wejściowych. Jak można zauważyć im większa ilość neuronów w warstwie ukrytej tym wartość parametru specyficzności drastycznie zmalała mimo, że wartość parametru czułości zwiększyła się. Natomiast porównując $n = 2$ i $n = 3$ są one na podobnym poziomie jeśli chodzi o wartość czułości i specyficzności. Wartości błędów średniokwadratowych dla danych treningowych i testowych różnią się na korzyść $n = 3$, ponieważ przyjmują one mniejsze wartości niż dla $n = 2$. W realizacji II etapu przyjęliśmy właśnie $n = 3$.

3.5 Zmiana liczby neuronów w warstwie ukrytej

Celem ostatniej próby było sprawdzenie jaki wpływ na działanie sieci ma jednoczesna zmiana współczynnika szybkości uczenia oraz ilości neuronów w warstwie ukrytej. Próby dokonano dla $\alpha = 0.001, 0.01, 0.1, 0.5, 0.99$ oraz $n = 3, 6, 9$.


3.5.1 Wyniki

$\alpha = 0,001$

Tabela 20. Zestawienie wyników dla $\alpha = 0.001$ przy różnej ilości neuronów w warstwie ukrytej


Liczba neuronów	3	6	9
Czułość	0,8182	0,7973	0,7586
Specyficzność	0,8060	0,8857	0,9070
Błąd MSE treningowe	0,00014	0,00013	0,00012
Błąd MSE testowe	0,1875	0,1597	0,1528

$n = 3$




Wykres 20. Wykres wartości błędów MSE w funkcji iteracji $\alpha = 0.001$ i $n=3$

$n = 6$



Wykres 21. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.001$ i $n=6$

$n = 9$




Wykres 22. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.001$ i $n=9$

$\alpha = 0,01$

Tabela 21. Zestawienie wyników dla $\alpha = 0.01$ przy różnej ilości neuronów w warstwie ukrytej


Liczba neuronów	3	6	9
Czułość	0,7385	0,7600	0,9103
Specyficzność	0,9241	0,8986	0,6818
Błąd MSE treningowe	0,00015	0,00012	0,00010
Błąd MSE testowe	0,1597	0,1736	0,1944

$n = 3$




Wykres 23. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.01$ i $n=3$

$n = 6$



Wykres 24. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.01$ i $n=6$

$n = 9$




Wykres 25. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.01$ i $n=9$

$\alpha = 0,1$

Tabela 22. Zestawienie wyników dla $\alpha = 0.1$ przy różnej ilości neuronów w warstwie ukrytej

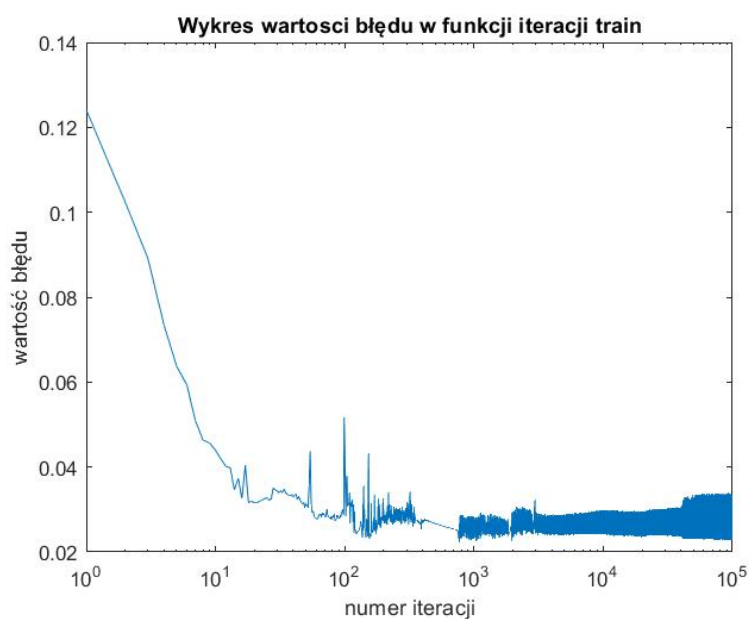
Liczba neuronów	3	6	9
Czułość	0,1930	0,1143	0,0556
Specyficzność	0,9770	0,9730	0,9861
Błąd MSE treningowe	0,00018	0,00006	0,00006
Błąd MSE testowe	0,3333	0,4444	0,4792

$n = 3$




Wykres 26. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.1$ i $n=3$

$n = 6$



Wykres 27. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.1$ i $n=6$

$n = 9$




Wykres 28. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.1$ i $n=9$

$\alpha = 0,5$

Tabela 23. Zestawienie wyników dla $\alpha = 0.5$ przy różnej ilości neuronów w warstwie ukrytej

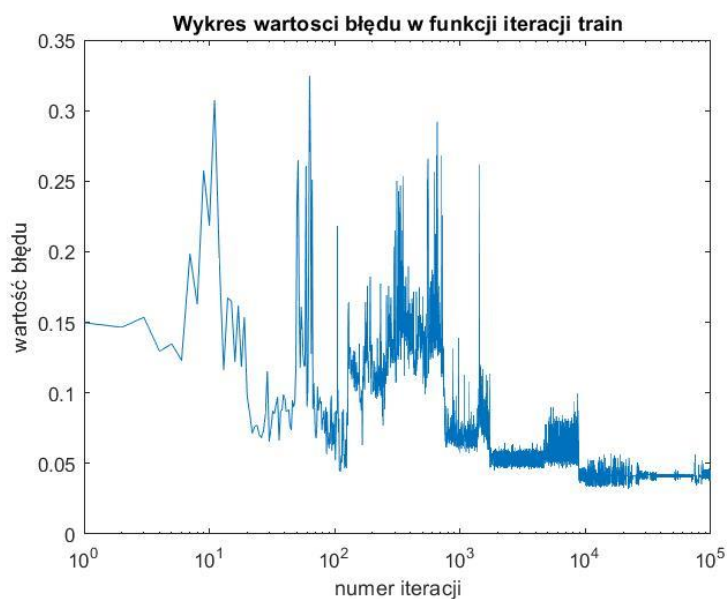
Liczba neuronów	3	6	9
Czułość	0	0,7250	0,8657
Specyficzność	1	0,9531	0,8571
Błąd MSE treningowe	0,00013	0,00011	0,00028
Błąd MSE testowe	0,4861	0,1736	0,1389

$n = 3$



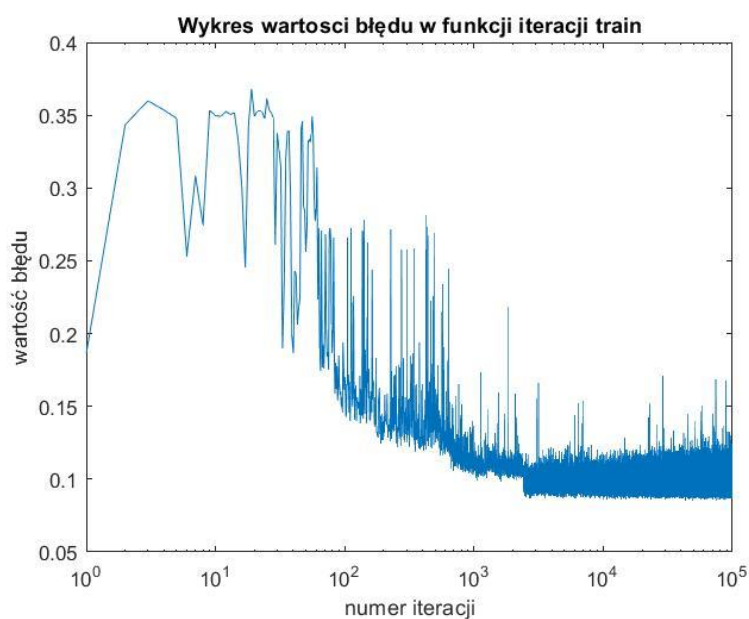
Wykres 29. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.5$ i $n=3$

$n = 6$



Wykres 30. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.5$ i $n=6$

$n = 9$




Wykres 31. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.5$ i $n=9$

$\alpha = 0,99$

Tabela 24. Zestawienie wyników dla $\alpha = 0.99$ przy różnej ilości neuronów w warstwie ukrytej


Liczba neuronów	3	6	9
Czułość	0	0,7856	0,8857
Specyficzność	1	0,6923	0,7703
Błąd MSE treningowe	0,00033	0,00086	0,00091
Błąd MSE testowe	0,4931	0,261	0,1736

$n = 3$




Wykres 32. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.99$ i $n=3$

$n = 6$



Wykres 33. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.99$ i $n=6$

$n = 9$



Wykres 34. Wykres wartości błędu MSE w funkcji iteracji $\alpha = 0.99$ i $n=9$


3.5.2 Porównanie uzyskanych wyników i wnioski

Na podstawie zaprezentowanych wyników różnych kombinacji współczynnika szybkości uczenia sieci i ilości neuronów w warstwie ukrytej dochodzi my do wniosku, że $\alpha = 0.001$ oraz $n = 3$ daje nam najbardziej skuteczne wartości. Czułość i specyficzność są na podobnym poziomie (zadawałający powyżej 80% w obu przypadkach) oraz błąd średniokwadratowy jest optymalny. Mimo kombinacji $\alpha = 0.01$ oraz $n = 3$ również dostajemy poprawne wyniki, ale za $\alpha = 0.001$ przemawia większa wartość parametru czułości.

4 Końcowy model sieci

4.1 Struktura sieci

Na podstawie przeprowadzonych różnych prób optymalizacji dochodzimy do wniosku, że nasze parametry początkowe były bardzo dobrze dobrane. Początkowe parametry to współczynnik szybkości uczenia wynosi 0.001 oraz liczba neuronów w warstwie ukrytej to 3. Ostateczny schemat sieci został przedstawiony na Rysunku 1.



Rysunek 1. Ostateczny schemat sieci

4.2 Algorytm uczenia

Zaimplementowany kod w MATLAB odpowiedzialny za uczenie sieci nie został zmieniony, ponieważ wartości przyjęte na samym początku zostały potwierdzone jako najbardziej optymalnymi wartościami dla naszej sieci.

4.3 Porównanie wyników przed optymalizacją z wynikami po optymalizacji


Jako, że nasze wartości od samego początku były poprawnie dobrane, postanowiliśmy przeprowadzić jeszcze jedno badanie dla kombinacji $\alpha = 0.01$ oraz $n = 3$. Jest to związane z uzyskaniem podobnych wartości jak w przypadku $\alpha = 0.001$ oraz $n = 3$.

Tabela 25. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,001$ oraz 3 neuronów w warstwie ukrytej

Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,8182	0,7838	0,8667	0,8000	0,6970	0,7206	0,78105
Specyficzność	0,8060	0,9143	0,8571	0,8649	0,9487	0,8421	0,87218
Błąd MSE treningowe	0,00014	0,00014	0,00015	0,00015	0,00014	0,00014	0,00014
Błąd MSE testowe	0,1875	0,1528	0,1389	0,1667	0,1667	0,2153	0,17132

Tabela 26. Wyniki uzyskane dla współczynnika uczenia sieci $\alpha = 0,01$ oraz 3 neuronów w warstwie ukrytej


Numer próby	1	2	3	4	5	6	Średnia
Czułość	0,5968	0,7123	0,3519	0,6290	0,6912	0,6761	0,60955
Specyficzność	0,9390	0,8873	0,9778	0,9390	0,9342	0,9589	0,93937
Błąd MSE treningowe	0,00014	0,00013	0,00021	0,00015	0,00015	0,00015	0,00016
Błąd MSE testowe	0,2083	0,2014	0,2569	0,1944	0,1806	0,1806	0,2037




Wykres 35. Wykres wartości czułości przy różnych wartościach współczynnika szybkości uczenia dla 3 neuronów w warstwie ukrytej



Wykres 36. Wykres wartości specyficzności przy różnych wartościach współczynnika szybkości uczenia dla 3 neuronów w warstwie ukrytej



Wykres 37. Wykres wartości błędu średniokwadratowego dla danych treningowych przy różnych wartościach współczynnika szybkości uczenia dla 3 neuronów w warstwie ukrytej



Wykres 38. Wykres wartości błędu średniokwadratowego dla danych testowych przy różnych wartościach współczynnika szybkości uczenia dla 3 neuronów w warstwie ukrytej

Na podstawie powyższych wyników stwierdzamy, że przy współczynniku szybkości uczenia $\alpha = 0.001$ i $\alpha = 0.01$ wyniki są dość zbliżone do siebie. Na korzyść $\alpha = 0.001$ przemawia mniejsza wartość błędu średniokwadratowego oraz większa wartość czułości.

5 Bibliografia

1. [UCI Machine Learning Repository: Mammographic Mass Data Set](#)
2. prezentacje do wykładu SNB - Sieci neuronowe w zastosowaniach biomedycznych

6 Oświadczenie

Oświadczam, że niniejsza praca stanowiąca podstawę do uznania osiągnięcia efektów uczenia się z przedmiotu *Sieci neuronowe w zastosowaniach biomedycznych (SNB)* została wykonana przeze mnie samodzielnie.

Adamczyk Jagoda, 289214
Krakowiak Aleksandra, 290292